Overovanie faktov na základe prehľadávania webu

Plán bakalárskeho projektu

Vladyslav Morhai
Technická univerzita v Košiciach, FEI

2026

Vedúci projektu: doc. Ing. Marián Mach, CSc.

Abstrakt

Práca sa zaoberá automatizovaným overovaním faktov na základe vyhľadávania na webe. Navrhujeme modulárny pipeline, ktorý pre zadané tvrdenie vygeneruje vyhľadávací dopyt, získa relevantné webové stránky, z ich plného textu pomocou modelu NLI určí, či tvrdenie potvrdzujú alebo vyvracajú, a výsledky agreguje do verdiktu s mierou istoty a zoznamom dôkazov. Agregáciu rozširujeme o váhy dôveryhodnosti zdrojov. Systém vyhodnotíme na datasete AVeriTeC a experimentálne overíme prínos jednotlivých častí. Ak to čas dovolí, porovnáme ho aj s prístupom založeným na veľkom jazykovom modeli, ktorý pracuje len s úryvkami z výsledkov vyhľadávania. Prínosom má byť transparentnejší a na referenčných dátach vyhodnotený postup.

1 Úvod a motivácia

Rýchlosť, akou sa informácie a dezinformácie šíria v online priestore, zvyšuje význam overovania faktov (angl. *fact-checking*) [3]. Overenie jedného tvrdenia pritom môže profesionálnym overovateľom trvať hodiny až dni [3], preto sa výskum zameriava na jeho automatizáciu pomocou metód spracovania prirodzeného jazyka a strojového učenia [3].

Overovanie tvrdení len na základe znalostí uložených v jazykovom modeli je problematické: takýto prístup môže prenášať skreslenia z trénovania a neumožňuje podložiť verdikt dôkazmi [3]. Veľké jazykové modely (LLM) navyše môžu generovať presvedčivo znejúce, no nepravdivé odpovede (halucinácie). Preto vznikajú prístupy, ktoré odpoveď modelu opierajú o výsledky vyhľadávania na webe, napríklad agent opísaný v [8]. V tomto riešení však chýba vyhodnotenie kvality verdiktov na dátach aj posúdenie dôveryhodnosti použitých zdrojov.

Cieľom tohto projektu je navrhnúť a implementovať systém, ktorý pre zadané tvrdenie vyhľadá relevantné webové zdroje, určí, či ich obsah tvrdenie potvrdzuje alebo vyvracia, a zostaví z toho verdikt s dôkazmi. Ak to čas dovolí, porovnáme ho s prístupom, v ktorom verdikt určuje LLM nad úryvkami z výsledkov vyhľadávania [8].

2 Cieľ projektu

Hlavným cieľom projektu je navrhnúť, implementovať a vyhodnotiť systém na overovanie faktov, ktorý pre zadané tvrdenie vyhľadá relevantné zdroje na webe, určí ich vzťah k tvrdeniu a zostaví z neho verdikt s dôkazmi.

Na dosiahnutie hlavného cieľa sú stanovené tieto čiastkové ciele:

1. Preštudovať existujúce prístupy k automatizovanému overovaniu faktov, najmä riešenia založené na vyhľadávaní na webe a na veľkých jazykových modeloch.

2. Navrhnúť a implementovať modulárny pipeline: generovanie vyhľadávacieho dopytu, vyhľadávanie na webe, sťahovanie a čistenie plného textu stránok, určenie vzťahu medzi tvrdením a textom pomocou modelu NLI a agregácia výsledkov do verdiktu.

3. Rozšíriť agregáciu o váhy dôveryhodnosti zdrojov.

4. Vyhodnotiť systém na datasete AVeriTeC pomocou štandardných metrík a overiť prínos jednotlivých častí systému.

5. Ak to čas dovolí, porovnať výsledky systému s prístupom založeným na LLM podľa [8] na rovnakej množine tvrdení.

3 Prehľad existujúcich riešení

Podľa [3] sa automatizované overovanie faktov člení na tri etapy: detekciu tvrdení, vyhľadanie dôkazov a overenie tvrdenia, ktoré zahŕňa predikciu verdiktu a tvorbu zdôvodnenia. Táto kapitola zhŕňa datasety, modely a prístupy k jednotlivým etapám, ktoré sú relevantné pre navrhované riešenie, a nakoniec stručne rozoberá, nakoľko je riešenie závislé od jazyka.

3.1 Datasety

Dataset FEVER [11][1] obsahuje približne 185 000 tvrdení vytvorených úpravou viet z Wikipédie. Každé tvrdenie je označené ako Supported, Refuted alebo NotEnoughInfo a pri prvých dvoch triedach je zaznamenaná aj veta, ktorá slúži ako dôkaz. Tvrdenia sú však umelé a overujú sa voči Wikipédii, nie voči otvorenému webu. Tieto nedostatky rieši dataset AVeriTeC [9][2], ktorý obsahuje 4 568 reálnych tvrdení z fact-checkov 50 organizácií. Ku každému tvrdeniu patria otázky a odpovede podložené dôkazmi dostupnými online a textové zdôvodnenie verdiktu. Autori sa pri anotácii snažili vylúčiť dôkazy zverejnené až po vzniku tvrdenia, no zaručujú to len približne. K trom triedam FEVER pridáva štvrtú: protichodné dôkazy alebo výber len vhodných faktov (angl. *conflicting evidence/cherry-picking*). Dataset je nevyvážený, pretože fact-checkeri vyberajú najmä nepravdivé alebo zavádzajúce tvrdenia, a obsahuje len anglické tvrdenia. Autori spolu s datasetom publikovali aj základný systém (angl. *baseline*), ktorý ďalej nazývame *základný systém AVeriTeC*; samotný dataset a tento systém sú dve odlišné veci.

Pre slovenčinu existuje dataset výrokov z Demagog.sk[3] s približne 20 000 výrokmi so štyrmi triedami verdiktov, ku ktorým sú pripojené texty fact-checkov a odkazy na použité zdroje. Nemá však štruktúru otázok a odpovedí s dôkazmi z webu ako AVeriTeC.

3.2 Modely pre odvodzovanie z textu (NLI)

Overenie tvrdenia voči textu možno formulovať ako úlohu odvodzovania z textu (angl. *natural language inference*, NLI): model určí, či text tvrdenie potvrdzuje (*entailment*), vyvracia (*contradiction*) alebo sa ho netýka (*neutral*) [3]. Modely pre túto úlohu vznikajú dotrénovaním predtrénovaného jazykového modelu na korpusoch ako MultiNLI. Moderným základom takýchto modelov je architektúra DeBERTa [6] a jej vylepšená verzia DeBERTaV3 [5], ktorej veľká verzia dosiahla na benchmarku GLUE priemerné skóre 91,37 %, čo je o 1,37 % viac než pôvodná DeBERTa. Základný systém AVeriTeC [9] používa podobný princíp: dotrénovaný model BERT-large označí každý pár otázka–odpoveď ako podporujúci, vyvracajúci alebo irelevantný a verdikt sa určí z týchto označení. Tento prístup však zlyhával pri triede protichodných dôkazov, pretože otázky len dopĺňajúce kontext model často chybne označil ako vyvracajúce.

[1] `https://fever.ai/dataset/fever.html`
[2] `https://fever.ai/dataset/averitec.html`
[3] `https://huggingface.co/datasets/NaiveNeuron/DemagogSK`

3.3 Detekcia tvrdení a dôveryhodnosť zdrojov

Prvou etapou je detekcia tvrdení, ktoré stoja za overenie. Systém ClaimBuster [4] v texte vyhľadáva overiteľné faktické tvrdenia. Táto etapa nie je súčasťou projektu, vstupom je už vybrané tvrdenie. Dôveryhodnosť zdroja, ktorú využíva rozšírená agregácia, sa skúma samostatne: práca [1] predikuje faktickú spoľahlivosť a politické skreslenie spravodajských zdrojov ako celku, nie jednotlivých článkov. Podobne chceme dôveryhodnosť priraďovať zdroju (doméne), nie jednotlivému textu.

3.4 Prístupy založené na LLM a vyhľadávaní

Veľké jazykové modely (LLM) dokážu tvrdenie posúdiť aj bez dodatočných dokumentov, no môžu si vymýšľať fakty a verdikt nemožno podložiť zdrojom. Preto sa využíva generovanie rozšírené o vyhľadávanie (angl. *retrieval-augmented generation*, RAG): model najprv dostane dokumenty nájdené k otázke a odpovedá podľa nich [7]. Tento prístup použil napríklad tím UHH : z dôkazov vybral najrelevantnejšie a LLM z nich určil verdikt[10].

Dve novšie práce riešia slabé miesta takého postupu. Systém FIRE [13] nehľadá dôkazy v pevnom počte krokov: model po každom kroku buď dá konečnú odpoveď, alebo vygeneruje nový dopyt, podľa toho, ako si je istý. Autori uvádzajú, že tým znížili náklady na LLM v priemere 7,6-krát a náklady na vyhľadávanie 16,5-krát pri mierne lepších výsledkoch. Práca [2] sa zaoberá situáciou, keď si zdroje protirečia, najmä keď sa líšia dôveryhodnosťou. Súčasné RAG metódy v takých prípadoch zlyhávajú a pomáha ich zlepšiť, ak model pri vyhľadávaní aj generovaní dostane informáciu o dôveryhodnosti zdroja. Práve to chceme využiť v rozšírenej agregácii (modul 6).

Agent opísaný v [8] pracuje podľa schémy *Perceive–Reason–Act*. Menší model LLM najprv rozhodne, či sa má tvrdenie rozložiť na viacero čiastkových vyhľadávacích dopytov. Dopyty sa vyhľadajú v Google cez komerčné SERP API a z výsledkov sa ponechajú nadpisy, popisy, odkazy, údaje z Knowledge Graph a súvisiace otázky. Tieto údaje dostane reasoning model s pokynom opierať sa len o ne a vráti verdikt zo šiestich tried, vysvetlenie a mieru istoty v rozsahu 0–100 podľa vopred definovanej schémy. Agent pracuje len s úryvkami z výsledkov vyhľadávania, nie s plným textom stránok, a nevyhodnocuje kvalitu verdiktov na dátach; uvedený je len jeden ukážkový príklad. Dôveryhodnosť zdrojov sa v zobrazenom pokyne pre model explicitne neposudzuje.

3.5 Jazyková nezávislosť

Navrhovaný pipeline je v zásade nezávislý od jazyka. Od jazyka závisia len dve časti: generovanie vyhľadávacieho dopytu (modul 2), ktoré využíva analyzátor slovných druhov, a model NLI (modul 5), ktorý je dotrénovaný na anglických dátach. Ostatné moduly, teda vyhľadávanie, sťahovanie textu, agregácia a výstup, s jazykom nesúvisia. Pre slovenčinu by sa preto nahradili len tieto dve časti slovenským analyzátorom a viacjazyčným alebo slovenským modelom NLI.

Na vyhodnotenie pre slovenčinu by sa dal použiť dataset výrokov z Demagog.sk, ktorý obsahuje verdikty, texty fact-checkov a odkazy na použité webové zdroje. Má však iné triedy verdiktov (pravda, nepravda, zavádzajúce, neoveriteľné) než AVeriTeC a texty zdrojov by sa museli stiahnuť zvlášť. Neobsahuje ani otázky a odpovede s priradenými dôkazmi.

3.6 Zhrnutie

Z prehľadu vyplýva, že existujú datasety s dôkazmi z webu [9], modely NLI na určenie vzťahu textu k tvrdeniu [5] aj prístupy založené na LLM [7, 13, 10]. Práca [2] ukazuje, že pri protichodných dôkazoch pomáha informácia o dôveryhodnosti zdroja. Agent opísaný v [8] však vyhodnocuje len úryvky z výsledkov vyhľadávania, nevyhodnocuje kvalitu verdiktov na dátach a dôveryhodnosť zdrojov v zobrazenom pokyne neposudzuje.

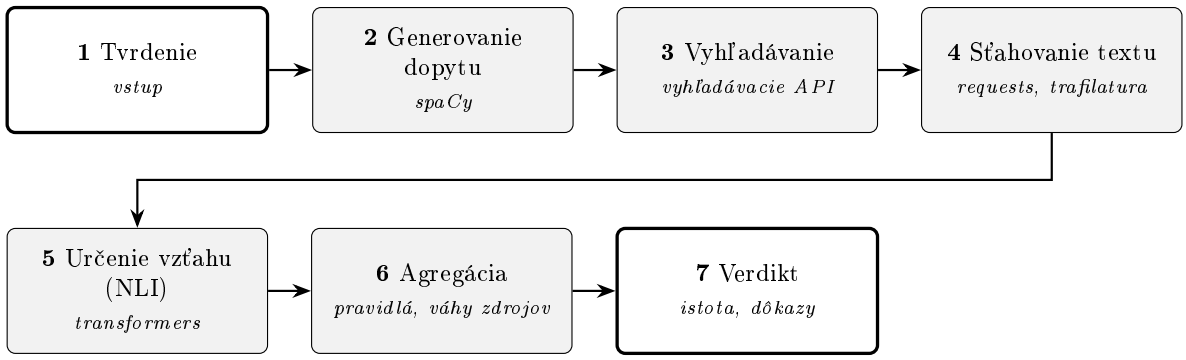
Navrhované riešenie preto:

- pracuje s plným textom stránok a modelom NLI namiesto úryvkov,

- pri agregácii zohľadňuje dôveryhodnosť zdroja podľa kategórie domény,
- vyhodnocuje verdikty na datasete AVeriTeC s referenčnými verdiktmi a overuje prínos jednotlivých častí.

4 Návrh riešenia

Navrhovaný systém je modulárny pipeline (obrázok 1), v ktorom každý modul rieši jednu úlohu a odovzdáva výsledok ďalšiemu. Pokrýva dve etapy z členenia v [3]: vyhľadanie dôkazov (moduly 2–4) a overenie tvrdenia (moduly 5–7). Detekcia tvrdení nie je súčasťou projektu, vstupom je jedno konkrétne tvrdenie. Verdikt nadobúda štyri hodnoty zodpovedajúce triedam datasetu AVeriTeC [9]: potvrdené, vyvrátené, protichodné dôkazy a nedostatok informácií. Dôkazy systém získava vyhľadávaním na webe.



Obr. 1: Schéma navrhovaného pipeline: z tvrdenia sa postupne získa vyhľadávací dopyt, zdroje a ich plný text, vzťah textu k tvrdeniu a nakoniec verdikt s mierou istoty a dôkazmi.

4.1 Moduly 1–2: Vstup a generovanie vyhľadávacieho dopytu

Vstupom je jedno tvrdenie v angličtine. Tvrdenie obsahuje slová (predložky, spojky, pomocné slovesá), ktoré pri vyhľadávaní prekážajú. Základný systém AVeriTeC preto vyhľadáva podľa skrátenej verzie tvrdenia, ktorá ponecháva len slovesá, podstatné mená a prídavné mená [9]. Rovnaký princíp použijeme aj my: knižnica spaCy určí slovné druhy a pomenované entity a do dopytu sa zaradia podstatné mená, vlastné mená, čísla, slovesá a prídavné mená. Kvalita dopytu je pre vyhľadávanie podstatná: autori AVeriTeC uvádzajú, že vyhľadávanie podľa tvrdenia a vygenerovaných otázok našlo užitočné dôkazy v 9 z 20 preskúmaných prípadov, kým s referenčnými otázkami v 16 z 20 [9]. Ako základná línia na porovnanie slúži odstránenie stop-slov, voliteľne sa zváži aj KeyBERT, ktorý vyberá frázy podľa významu celej vety.

4.2 Moduly 3–4: Vyhľadávanie a sťahovanie textu

Dopyt sa odošle do vyhľadávacieho API komerčného poskytovateľa (vyberie sa podľa dostupnosti bezplatného prístupu), ktoré vráti zoznam adries URL a krátkych úryvkov. Pre každú adresu sa stiahne HTML, pomocou knižnice `trafilatura` sa z neho extrahuje hlavný text bez navigácie a reklám a nedostupné stránky sa preskočia. Odpovede vyhľadávania a stiahnuté texty sa ukladajú do vyrovnávacej pamäte, aby sa pri opakovaných experimentoch nevyčerpával limit API a aby všetky porovnávané varianty systému pracovali s tými istými stránkami.

4.3 Modul 5: Určenie vzťahu medzi tvrdením a textom

Stiahnutý text sa rozdelí na vety. Pre každú dvojicu (tvrdenie, veta) model NLI určí jednu z troch tried: potvrdzuje, vyvracia, nesúvisí, spolu s pravdepodobnosťou každej z nich. Použije sa anglický predtrénovaný model založený na architektúre DeBERTa-v3 [5] dotrénovaný na korpuse MultiNLI [12] cez knižnicu `transformers`, takže netreba trénovať vlastný model. Do ďalšieho spracovania idú len vety s pravdepodobnosťou nad prahom, ktorý sa nastaví na časti trénovacej množiny datasetu AVeriTeC. Obmedzuje sa tým chybné označenie viet, ktoré len dopĺňajú kontext, ako vyvracajúcich; tento problém sa objavil pri základnom systéme AVeriTeC [9].

4.4 Moduly 6–7: Agregácia a výstup

Základná agregácia vychádza z pravidla použitého v základnom systéme AVeriTeC [9]: ak sú medzi dôkazmi aj potvrdzujúce, aj vyvracajúce, verdikt je protichodné dôkazy; ak len potvrdzujúce, potvrdené; ak len vyvracajúce, vyvrátené; inak nedostatok informácií. Rozšírená verzia váži každý dôkaz mierou istoty modelu a dôveryhodnosťou zdroja, ktorá sa odhadne podľa kategórie domény (napr. vládne a akademické domény, spravodajské weby, sociálne siete a blogy), aby niekoľko slabých zdrojov neprevážilo kvalitné. Výstupom je verdikt, celková miera istoty a zoznam dôkazov s adresami zdrojov. Zoznam dôkazov je len základnou formou zdôvodnenia, ktorá neodhaľuje celé uvažovanie systému [3]. Prvá verzia používa konzolové rozhranie, jednoduché webové rozhranie je voliteľné.

5 Experimentálne vyhodnotenie

5.1 Dáta

Na vyhodnotenie sa použije dataset AVeriTeC [9], ktorý obsahuje reálne tvrdenia s dôkazmi z webu a pri ktorého tvorbe sa autori snažili obmedziť dôkazy na dokumenty zverejnené pred vznikom tvrdenia. Verdikty datasetu (potvrdené, vyvrátené, nedostatok informácií, protichodné dôkazy) zodpovedajú výstupom systému. Dataset je nevyvážený: vyvrátené tvrdenia tvoria približne 61 až 62 % validačnej a testovacej množiny [9]. Parametre systému (napr. prah v module 5) sa nastavia na časti trénovacej množiny a vyhodnotenie prebehne na validačnej množine datasetu. Vyhodnocuje sa na náhodnej podmnožine tvrdení s pevným semienkom generátora náhodných čísel, ktorej veľkosť závisí od limitov vyhľadávacieho API.

Tvrdenia v datasete pochádzajú z fact-checkov z rokov 2020 až 2021, preto by vyhľadávanie mohlo nájsť samotný fact-check s hotovým verdiktom. Aby sa tomu zabránilo, zo zdrojov sa vylučujú weby fact-checkingových organizácií [9]. Úplne vylúčiť únik verdiktu sa však nedá, pretože ho môžu prebrať aj iné články.

5.2 Metriky

Kvalita verdiktov sa meria presnosťou (*accuracy*), makro F1-skóre a maticou zámen, aby bolo vidno chovanie pre každú triedu. Pre nevyváženosť datasetu je hlavnou metrikou makro F1-skóre.

5.3 Porovnávané systémy

1. **Základný pipeline**: navrhnutý systém s pravidlovou agregáciou.
2. **Rozšírený pipeline**: agregácia vážená dôveryhodnosťou zdrojov.
3. **Prístup založený na LLM** : reimplementácia agenta podľa [8] v jazyku Python, ktorý určuje verdikt nad úryvkami z výsledkov vyhľadávania.

Všetky porovnávané systémy dostanú rovnaké tvrdenia a rovnaké uložené výsledky vyhľadávania; líšia sa tým, ako s nimi naložia.

5.4 Ablačné experimenty

Prínos jednotlivých častí sa overí ich vypnutím: porovnanie plného textu stránok s úryvkami (cieľ 2) a porovnanie pravidlovej agregácie s váženou (cieľ 3). Súčasťou vyhodnotenia je aj kvalitatívna analýza chýb na vybraných príkladoch.

5.5 Obmedzenia

Dôveryhodnosť zdrojov sa odhaduje len podľa kategórie domény, čo je hrubé priblíženie. Dataset obsahuje len anglické tvrdenia. Pri voliteľnom porovnaní s LLM treba počítať s tým, že model mohol počas trénovania vidieť aj tvrdenia z datasetu, čo môže skresliť výsledok.

6 Použité technológie

Systém sa implementuje v jazyku Python. Použité nástroje:

- `spaCy` – určovanie slovných druhov a rozpoznávanie pomenovaných entít pri generovaní vyhľadávacieho dopytu,
- API komerčného poskytovateľa vyhľadávania na webe,
- `requests` a `trafilatura` – sťahovanie stránok a extrakcia hlavného textu,
- `transformers` a `PyTorch` – modely NLI,
- `scikit-learn` – výpočet metrík,
- voliteľne API veľkého jazykového modelu – len pre porovnávaný prístup podľa [8],
- Git a LaTeX – správa kódu a dokumentácie.

Literatúra

[1] Ramy Baly, Georgi Karadzhov, Dimitar Alexandrov, James Glass, and Preslav Nakov. Predicting factuality of reporting and bias of news media sources. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 3528–3539, Brussels, Belgium, 2018. Association for Computational Linguistics.

[2] Ziyu Ge, Yuhao Wu, Daniel Wai Kit Chin, Roy Ka-Wei Lee, and Rui Cao. Resolving conflicting evidence in automated fact-checking: A study on retrieval-augmented LLMs, 2025. arXiv:2505.17762.

[3] Zhijiang Guo, Michael Schlichtkrull, and Andreas Vlachos. A survey on automated fact-checking. *Transactions of the Association for Computational Linguistics*, 10, 2022.

[4] Naeemul Hassan, Fatma Arslan, Chengkai Li, and Mark Tremayne. Toward automated fact-checking: Detecting check-worthy factual claims by ClaimBuster. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '17)*, Halifax, NS, Canada, 2017. ACM.

[5] Pengcheng He, Jianfeng Gao, and Weizhu Chen. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. In *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2111.09543.

[6] Pengcheng He, Xiaodong Liu, Jianfeng Gao, and Weizhu Chen. DeBERTa: Decoding-enhanced BERT with disentangled attention. In *International Conference on Learning Representations (ICLR)*, 2021. arXiv:2006.03654.

[7] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020. arXiv:2005.11401.

[8] Prithwish Nath. I built an AI agent that fact-checks claims with Google + GPT. Plain English (ai.plainenglish.io).

[9] Michael Schlichtkrull, Zhijiang Guo, and Andreas Vlachos. AVeriTeC: A dataset for real-world claim verification with evidence from the web. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*, 2023.

[10] Özge Sevgili, Irina Nikishina, Seid Muhie Yimam, Martin Semmann, and Chris Biemann. UHH at AVeriTeC: RAG for fact-checking with real-world claims. In *Proceedings of the Seventh Fact Extraction and VERification Workshop (FEVER)*, Miami, Florida, USA, 2024. Association for Computational Linguistics.

[11] James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, 2018. Anthology ID: N18-1074.

[12] Adina Williams, Nikita Nangia, and Samuel R. Bowman. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, New Orleans, Louisiana, 2018.

[13] Zhuohan Xie, Rui Xing, Yuxia Wang, Jiahui Geng, Hasan Iqbal, Dhruv Sahnan, Iryna Gurevych, and Preslav Nakov. FIRE: Fact-checking with iterative retrieval and verification, 2024. arXiv:2411.00784.